Métodos de MCMC en Modelos gráficas aleatorias exponenciales

Hermilo

31 de octubre de 2022

Modelos de ERG (Fronczak, 2012)

Motivación

Los modelos de ERG son útiles cuando se quiere crear modelos de redes que tengan, lo más cercano posible, las propiedades observadas de las redes reales a estudiar, sin entrar en detalle del proceso subyacente de la formación de la red.

- Supongamos que tenemos una red del mundo real y queremos crear su modelo de ensamble.
- Las **propiedades observables** de una gráfica son aquellas propiedades que son medibles y que queremos reflejar en el modelo.
- Ejemplos:
  - Número de aristas.
  - Secuencia de grado, $\{k_i\} = k_1, k_2, \ldots, k_n$.
  - Trayectoria promedio más corta.
  - Coeficiente de clustering.

- Se especifica la colección de todas las posibles realizaciones que se pueden esperar de la red real.
- Es decir, se tiene que definir el conjunto de gráficas $\mathcal{G} = \{G\}$ a estudiar.
- El objetivo es encontrar la distribución de probabilidad $P(G)$ sobre el conjunto de todas las posibles realizaciones de $\mathcal{G} = \{G\}$.

- En el modelo ERG la distribución de probabilidad, $P(G)$, tiene la forma:

$$P(G) = \frac{e^{H(G)}}{Z} \tag{1}$$

- donde Z es llamada la función de partición y puede ser calculada de la condición de normalización:

$$\sum_{G \in \mathcal{G}} P(G) = \frac{1}{Z} \sum_{G \in \mathcal{G}} e^{H(G)} = 1 \tag{2}$$

- que implica

$$Z = \sum_{G \in \mathcal{G}} e^{H(G)} \tag{3}$$

- El Hamiltoniano en la ecuación 1 está dado por:

$$H(G) = \sum_{i=1}^{r} \theta_i x_i(G) \tag{4}$$

- donde $\{x_i(G)\}$ son los valores de los observables $\{x_i\}$ para cada gráfica G, mientras $\{\theta_i\} = \theta_1, \ldots, \theta_r$ son parámetros del ensamble que se dice se conjugan con los obserbables de tal manera que el valor, x_i^*, medido en la red real es igual al correspondiente valor promedio dentro del ensamble, *i.e.*:

$$\langle x_i \rangle = \sum_{G \in \mathcal{G}} x_i(G) P(G) = x_i^* \qquad \text{para} \qquad i = 1, \ldots, r \tag{5}$$

El ensamble queda definido si se especifican:

- Las realizaciones plausibles de la red, $\mathcal{G} = \{G\}$
- Los observables, $\{x_i\}$, que aparecen en el Hamiltoniano.

Los parámetros del ensamble, $\{\theta_i\}$, utilizados en el Hamiltoniano se calculan (analiticamente o numéricamente) de las restricciones del ensamble.

Algoritmo de Metrópolis (Hoff, 2009)

- Considerando el caso en que se tiene un modelo muestral $Y \sim p(y|\theta)$ y una distribución inicial $p(\theta)$.
- La distribución final es difil de calcular por la integral en el denominador:

$$p(\theta|y) = \frac{p(\theta)p(y|\theta)}{\int p(\theta')p(y|\theta')d\theta'} \tag{6}$$

- Si se pudiera obtener muestras de $p(\theta|y)$, se podría generar $\theta^{(1)}, \theta^{(2)}, \ldots, \theta^{(S)} \sim$ i.i.d.$p(\theta|y)$ y obtener aproximaciones con el método de Monte Carlo.
- El problema es cuando no se pueden obtener muestras directamente de $p(\theta|y)$.

- En términos de aproximar la distribución posterior, lo crítico no es tener muestras i.i.d. de $p(\theta|y)$ sino que poder construir una gran colección de valores de θ, cuya distribución empírica aproxime $p(\theta|y)$
- Suponiendo que se cuenta con una colección $\{\theta^{(1)}, \theta^{(2)}, \ldots, \theta^{(s)}\}$ a la cual queremos agregar un valor nuevo θ^{s+1}.
- Se considera agregar un valor θ^* que es cercano a θ^s.
- **¿Qué regla de decisión utilizamos?**

- Si $p(\theta^*|y) > p(\theta^{(s)}|y)$, se prefieren más valores de θ^* en el conjunto que los valores de $\theta^{(s)}$.
- Dado que $\theta^{(s)}$ ya está en el conjunto, entonces parece que deberíamos incluir también a θ^*.
- En el caso contrario, si $p(\theta^*|y) < p(\theta^{(s)}|y)$ no es necesario incluir θ^*.
- Así, parece que la decisión de incluir o no a θ^* depende de la comparación entre $p(\theta^*|y)$ y $p(\theta^{(s)}|y)$.
- Afortunadamente, esta comparación se puede hacer incluso si no podemos calcular $p(\theta|y)$

$$r = \frac{p(\theta^*|y)}{p(\theta^{(s)}|y)} = \frac{p(y|\theta^*)p(\theta^*)}{p(y)} \frac{p(y)}{p(y|\theta^{(s)})p(\theta^{(s)})} = \frac{p(y|\theta^*)p(\theta^*)}{p(y|\theta^{(s)})p(\theta^{(s)})} \tag{7}$$

Habiendo calculado r, ¿qué tenemos que hacer?

- Si $r > 1$:
  - **Intuición**: Dado que $\theta^{(s)}$ ya está en el conjunto, debemos incluir a θ^* ya que tiene una probabilidad mayor que $\theta^{(s)}$.
  - **Decisión**: Aceptar θ^* en nuestro conjunto, *i.e.* definir $\theta^{s+1} = \theta^*$.
- Si $r < 1$:
  - **Intuición**: La frecuencia relativa de valores θ en el conjunto que es igual a θ^*, comparado con aquellos valores iguales a $\theta^{(s)}$ está dada por la expresión $\dfrac{p(\theta^*|y)}{p(\theta^{(s)}|y)} = r$. Esto significa que por cada instancia de $\theta^{(s)}$, deberíamos tener sólo una fracción de valores θ^*.
  - **Decisión**: Definir θ^{s+1} igual a θ^* o $\theta^{(s)}$ con probabilidad r y $1 - r$ respectivamente.

Algoritmo Metropolis

- Lo anterior es la intuición básica del algoritmo de **Metropolis**.
- El algoritmo de Metropolis procede al muestrear un valor θ^* cercano al valor actual $\theta^{(s)}$ usando una distribución simétrica $J(\theta^*|\theta^{(s)})$.
- En este contexto, simetría significa que $J(\theta_b|\theta_a) = J(\theta_a|\theta_b)$, *i.e.* la probabilidad de proponer $\theta^* = \theta_b$ dado que $\theta^{(s)} = \theta_a$ es igual a la probabilidad de proponer $\theta^* = \theta_a$ dado que $\theta^{(s)} = \theta_b$.
- Algunos ejemplos de $J(\theta^*|\theta^{(s)})$ son :
  - $J(\theta^*|\theta^{(s)}) = \text{uniform}(\theta^{(s)} - \delta, \theta^{(s)} + \delta)$
  - $J(\theta^*|\theta^{(s)}) = \text{normal}(\theta^{(s)}, \delta^2)$
- El valor del parámetro δ generalmente se elige para hacer que el algoritmo se ejecute de manera eficiente.

- **Habiendo obtenido un valor propuesto θ^* se añade al conjunto este valor o a una copia de $\theta^{(s)}$, dependiendo de la proporción** $r = \dfrac{p(\theta^*|y)}{p(\theta^{(s)}|y)}$

De forma específica, dado $\theta^{(s)}$, el algoritmo Metropolis genera un valor $\theta^{(s+1)}$ de la siguiente forma:

1. Tomar una muestra $\theta^* \sim J(\theta|\theta^{(s)})$
2. Calcular la proporción de aceptación

$$r = \frac{p(\theta^*|y)}{p(\theta^{(s)}|y)} = \frac{p(y|\theta^*)p(\theta^*)}{p(y|\theta^{(s)})p(\theta^{(s)})}$$

3. Sea

$$\theta^{(s+1)} = \begin{cases} \theta^* & \text{con probabilidad } \text{mín}(r,1) \\ \theta^{(s)} & \text{con probabilidad } 1 - \text{mín}(r,1) \end{cases} \tag{8}$$

El paso 3 se puede obtener al tomar una muestra $u \sim \text{uniform}(0,1)$ y definir $\theta^{s+1} = \theta^*$ si $u < r$ y $\theta^{s+1} = \theta^{\theta^{(s)}}$ en otro caso.

Ejemplo con una distribución normal con varianza conocida

Sea $\theta \sim \text{normal}(\mu, \tau^2)$ y $\{y_1, \ldots, y_n|\theta\} \sim \text{i.i.d. normal}(\theta, \sigma^2)$, la distribución posterior de θ es $\text{normal}(\mu_n, \tau_n^2)$ donde

$$\mu_n = \bar{y}\frac{\frac{n}{\sigma^2}}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}} + \mu\frac{\frac{n}{\tau^2}}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}$$

$$\tau_n^2 = \frac{1}{\frac{n}{\sigma^2} + \frac{1}{\tau^2}}$$

Supongamos que $\sigma^2 = 1, \tau^2 = 10, \mu = 5, n = 5$ y
$\text{y} = \{9{,}37, 10{,}18, 9{,}16, 11{,}60, 10{,}33\}$.
Con estos datos, $\mu_n = 10{,}03$ y $\tau_n^2 = 0{,}2$, de manera que
$p(\theta|\text{y}) = \text{dnorm}(10{,}03, 0{,}44)$

- Supongamos que no podemos obtener la distribución final, así que usamos el algoritmo Metropolis.
- La proporción de aceptación de un valor propuesto θ^* con respecto al valor actual $\theta^{(s)}$ es

$$r = \frac{p(\theta^*|\mathrm{y})}{p(\theta^{(s)}|\mathrm{y})} = \left(\frac{\prod_{i=1}^{n} \mathrm{dnorm}(y_i, \theta^*, \sigma)}{\prod_{i=1}^{n} \mathrm{dnorm}(y_i, \theta^{(s)}, \sigma)} \right) \times \left(\frac{\mathrm{dnorm}(\theta^*, \mu, \tau)}{\mathrm{dnorm}(\theta^{(s)}, \mu, \tau)} \right)$$

- En algunos casos calcular r directamente puede ser inestable, por lo que se sugiere calcular el logaritmo de r

$$\log r = \sum_{i=1}^{n} \Big[\log \mathrm{dnorm}(y_i, \theta^*, \sigma) - \log \mathrm{dnorm}(y_i, \theta^{(s)}, \sigma) \Big] + \\ \log \mathrm{dnorm}(\theta^*, \mu, \tau) - \log \mathrm{dnorm}(\theta^{(s)}, \mu, \tau)$$

- Manteniendo las cosas en la escala logarítmica, el valor propuesto se acepta si $\log u < \log r$, donde u es una muestra de una distribución uniforme en $(0, 1)$.

```julia
using Random, Distributions,Plots,StatsPlots

Random.seed!(123)

let
σ2 = 1 ; τ2=10; μ=5
y =[9.37,10.18,9.16,11.60,10.33]
θ=0; δ2 =2; S = 100000
theta = []

for s in 1:S

    θ_star = rand(Normal(θ,sqrt(δ2)),1)[1]
    verosimilitud = sum(logpdf.(Normal(θ_star,sqrt(σ2)), y) .+ logpdf.(Normal(μ,sqrt(τ2)), θ_star))
    inicial = sum(logpdf.(Normal(θ,sqrt(σ2)), y) .+ logpdf.(Normal(μ,sqrt(τ2)), θ))

    log_r= verosimilitud - inicial
    if log(rand(Uniform(0, 1),1)[1]) < log_r
        θ = θ_star
    end

    push!(theta,θ)
end
end
```

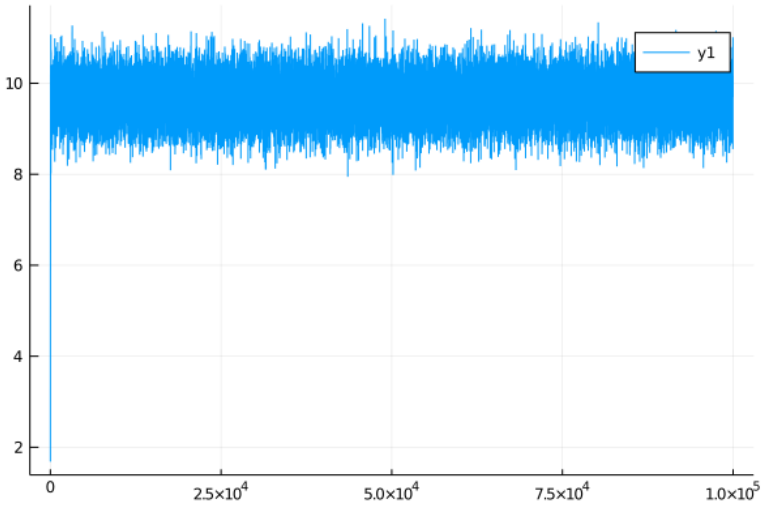

(a) Iteraciones

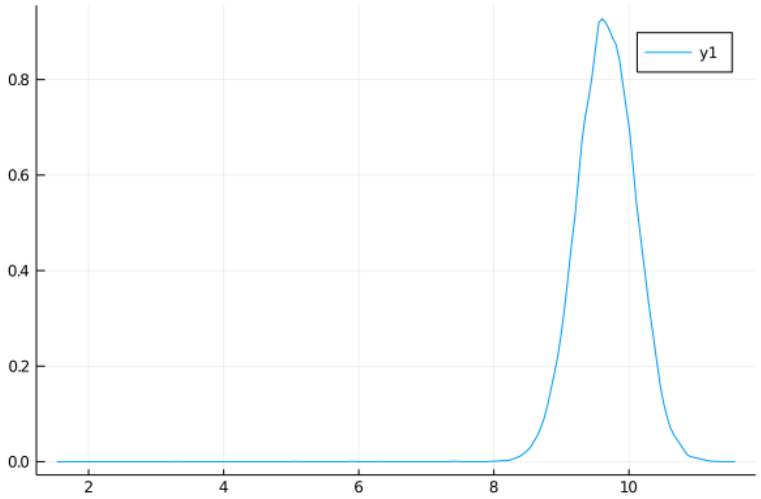

(b) Densidad estimada de θ

Algoritmo Metropolis-Hastings

- Considera una distribución de probabilidad objetivo bivariada para dos variables aleatorias U y V, $p_0(u, v)$.
- En problema de la distribución normal univariada, se tendría $U = \theta$ y $V = \sigma^2$ y $p_0(u, v) = p(\theta, \sigma^2|\mathrm{y})$.
- El algoritmo de Metropolis es un caso particular del algoritmo Metropolis-Hastings si J_u es simétrica, lo que significa que

$$J(u_a|u_b, v) = J(u_b|u_a, v)$$

- para todos los posibles u_a, u_b y v.

Simulaciones Monte Carlo para ERG

- Si los enfoques analíticos para calcular Z son intratables, el ensamble se puede estimar usando simulaciones de Monte Carlo, mediante el algoritmo Metropolis-Hastings.
- Para el método se define un conjunto de acciones en el espacio de las gráficas.
- De forma repetida se realizan acciones de este conjunto, las cuales se aceptan con probablidad:

$$p = 1 \qquad \text{si} \qquad P(G') > P(G) \tag{9}$$

- Donde $P(G')$ es la gráfica después de la ejecución de la acción, y

$$p = \frac{P(G')}{P(G)} \qquad \text{si} \qquad P(G') < P(G) \tag{10}$$

- La probabilidad de aceptación dada por 10 se puede calcular con la siguiente expresión:

$$p = e^{H(G')-H(G)} = e^{\Delta H} \qquad \text{si} \qquad \Delta H < 0 \tag{11}$$

- donde

$$\Delta H = \sum_{i=1}^{r} \theta_i (x_i(G') - x_i(G)) \tag{12}$$

- Usando ΔH, la condición de aceptación de un cambio (9) se puede escribir

$$p = 1 \qquad \text{si} \qquad \Delta H > 0 \tag{13}$$

- La elección del conjunto de movimientos depende del conjunto de todas las posibles realizaciones de la red , $\mathcal{G} = \{G\}$, subyacente al ensamble estudiado.
- Por ejemplo, algunos movimientos adecuados podrían ser:
  - Adición y eliminación de aristas entre pares de vértices elegidos al azar para el caso de gráficos que no tienen un número fijo de aristas.
  - Reconexiones de aristas de forma aleatoria para el caso de números de aristas fijos pero con secuencia de grados variable.
  - Cambios de aristas de la forma $\{(v_1, w_1), (v_2, w_2)\} \to \{(v_1, w_2), (v_2, w_1)\}$, para el caso de secuencia de grados fija donde (v_1, w_1) denota una arista del vértice v_1 al vértice w_1.

Ejemplo del algoritmo Metropolis-Hastings para una gráfica aleatoría con un número esperado de aristas

References I

Fronczak, A. (2012). *Exponential random graph models.*

Hoff, P. D. (2009). *A first course in bayesian statistical methods* (Vol. 580). Springer.